

Università degli Studi di Milano

FACOLTÀ DI SCIENZE E TECNOLOGIE

DIPARTIMENTO DI INFORMATICA

GIOVANNI DEGLI ANTONI



CORSO DI LAUREA TRIENNALE IN INFORMATICA

SVILUPPO DI APPROCCI DI ACTIVE VISIONE PER LA
GESTIONE DELLE OCCLUSIONI NELLA RACCOLTA
ROBOTIZZATA DI POMODORI

Relatore: Prof. [Nome Relatore]
Correlatore: Dott. [Nome Correlatore]

Elaborato Finale di:
Lorenzo Arienti
Matr. Nr. [Matricola]

ANNO ACCADEMICO 2024-2025

Sommario

Ringraziamenti

Indice

Sommario	i
Ringraziamenti	ii
Indice	iii
Elenco delle tabelle	v
Elenco delle figure	vi
1 Introduzione	1
1.1 Contesto e Motivazioni	1
1.2 Definizione del Problema	2
1.3 Obiettivi della Tesi	3
2 Stato dell’Arte	4
2.1 Computer Vision per l’Agricoltura di Precisione	4
2.2 Rilevamento e Segmentazione delle Istanze	5
2.3 Tecniche di Gestione delle Occlusioni in Letteratura	6
3 Metodologia e Pipeline Decisionale	9
3.1 Limiti delle Bounding Box e Modellazione Ellittica con Convex Hull	11
3.1.1 Limiti Geometrici delle Bounding Box Assiali	11
3.1.2 Modellazione tramite Convex Hull e Fitting Ellittico	12
3.2 Screening Dimensionale e Metriche di Raggiungibilità	13
3.2.1 Metriche di Valutazione Geometrica	14
3.2.2 Punteggio Geometrico Combinato	15
3.3 Deduplicazione, Selezione del Pool e Filtro di Maturità	16
3.3.1 Deduplicazione con Mask-IoU	16
3.3.2 Selezione del Pool di Candidati	17
3.3.3 Analisi del Colore nello Spazio HSV e Indice di Maturità	17

3.4	Risoluzione del Depth Ordering e Mappa delle Occlusioni	18
3.5	Algoritmo di Task Planning Dinamico	19
3.5.1	Penalizzazione delle Occlusioni e Punteggio Dinamico	19
3.5.2	Rimozione Virtuale e Meccanismo di Sblocco	20
4	Validazione Sperimentale e Discussione	22
4.1	Configurazione Sperimentale e Dataset di Test	22
4.1.1	Dataset e Immagini di Test	22
4.1.2	Configurazione del Modulo Percettivo (YOLOv11-seg)	23
4.1.3	Ambiente di Esecuzione e Parametri Operativi	23
4.2	Analisi Comparativa delle Strategie di Picking	23
4.2.1	Metodologia di Benchmark e Criteri di Valutazione	24
4.2.2	Risultati Quantitativi Globali	25
4.2.3	Origine Geometrica delle Divergenze	27
4.3	Analisi dei Casi Studio e Discussione	28
4.3.1	Dinamica di Sblocco delle Occlusioni	28
4.3.2	Inversione delle Priorità e Frutti Allungati	30
4.3.3	Limiti Sistemici e Condizioni Critiche	31
5	Conclusioni e Sviluppi Futuri	32
5.1	Sintesi dei Risultati e Contributi della Tesi	32
5.2	Sviluppi Futuri e Integrazione Robotica	34
	Bibliografia	36

Elenco delle tabelle

1	Pesi assegnati alle caratteristiche geometriche.	16
2	Riepilogo dei parametri e delle soglie operative della pipeline decisionale. .	24
3	Tasso di concordanza con il Ground Truth umano lungo la sequenza di raccolta.	25

Elenco delle figure

1	Schema a blocchi della pipeline decisionale: dall'immagine RGB acquisita in serra alla sequenza ordinata di raccolta per il manipolatore robotico. . .	10
2	Confronto geometrico su frutti adiacenti in diagonale: i limiti delle bounding box assiali (a) e la risoluzione tramite fitting ellittico (b).	12
3	Confronto tra preferenza umana e ottimizzazione geometrica	26
4	Confronto qualitativo delle strategie di picking su grappolo denso	27
5	Dinamica di sblocco su grappolo denso	29
6	Inversione delle priorità di picking su grappolo verticale	30

Capitolo 1

Introduzione

L'automazione della raccolta in serra tramite robot è uno dei temi più interessanti e attuali dell'agricoltura di precisione. In questo capitolo viene introdotto il contesto generale del lavoro, spiegando i motivi pratici ed etici per cui è utile automatizzare la raccolta dei pomodori. Successivamente viene descritto il problema principale affrontato nella tesi, ovvero la difficoltà di gestire le occlusioni all'interno dei grappoli densi, per poi presentare gli obiettivi principali del lavoro.

1.1 Contesto e Motivazioni

Il lavoro svolto in questa tesi fa parte di un progetto di ricerca più ampio del Dipartimento di Informatica dell'Università degli Studi di Milano, coordinato dai professori Nicola Basilico e Matteo Luperto, con l'obiettivo di applicare la robotica e l'intelligenza artificiale all'agricoltura di precisione.

Negli ultimi anni la coltivazione in serra ha avuto una grande diffusione, poiché permette di controllare l'ambiente di crescita delle piante, risparmiare acqua, limitare l'uso di pesticidi e produrre durante tutto l'anno. Nonostante questi miglioramenti tecnologici, la gestione della serra richiede ancora molto lavoro manuale, soprattutto per il controllo delle piante e per la raccolta dei frutti [1]¹.

In particolare, la raccolta del pomodoro è una delle attività più faticose e costose. Gli operatori devono lavorare per molte ore all'interno delle serre, dove le temperature e i livelli di umidità sono spesso molto alti. A questo si aggiunge la crescente difficoltà nel trovare manodopera stagionale, oltre a una motivazione etica molto importante: l'automazione di questi compiti faticosi può contribuire a ridurre fenomeni di sfruttamento e caporalato, ancora troppo presenti nel settore agricolo. L'uso di robot per la raccolta permetterebbe inoltre di lavorare in modo continuo, ottimizzando i tempi di produzione.

¹A. Gongal et al., «Sensors and Systems for Fruit Detection and Localization: A Review,» *Computers and Electronics in Agriculture*, vol. 116, pp. 8–19, 2015. DOI: 10.1016/j.compag.2015.05.021

In passato, i primi tentativi di automatizzare la raccolta si sono basati su macchine meccaniche come scuotitori o pettini. Questi sistemi funzionano a "ciclo aperto" (*open-loop*): scuotono l'intera pianta senza distinguere quali frutti siano pronti e quali no, rischiando di rovinare la pianta e provocando molti sprechi. L'obiettivo della robotica moderna è invece realizzare sistemi a "ciclo chiuso" (*closed-loop*), capaci di compiere una raccolta selettiva [2]²: il robot deve raccogliere soltanto i frutti maturi al punto giusto per il mercato, lasciando intatti quelli acerbi in modo che possano maturare nei giorni successivi.

Per fare questo, la visione artificiale è la componente fondamentale del robot. L'ambiente della serra è complesso e variabile: la luce solare cambia continuamente durante il giorno, c'è polvere e la vegetazione è molto fitta. Prima di poter muovere il braccio meccanico per afferrare un pomodoro, il sistema deve essere in grado di "vedere" e capire la scena: deve individuare dove si trovano i frutti, capire quali sono maturi e quali acerbi, e verificare se siano facili da raggiungere, così da evitare urti accidentali con i rami o con la pianta.

1.2 Definizione del Problema

All'interno di una serra, il compito di raccogliere i pomodori si scontra con una difficoltà fondamentale: la struttura biologica della pianta. I pomodori non crescono isolati su rami sgombri, ma si sviluppano aggregati in grappoli densi e compatti, circondati da foglie, rami di sostegno e dal fusto principale.

In una scena così affollata, la sola identificazione visiva dei frutti tramite i modelli classici di Object Detection non è sufficiente per guidare un braccio robotico. Questi modelli racchiudono solitamente gli oggetti all'interno di riquadri rettangolari rigidi (*bounding box*). Tuttavia, i pomodori hanno una sagoma tondeggianti o allungata: di conseguenza, i quattro angoli del rettangolo includono inevitabilmente una porzione consistente di spazio vuoto. Quando più pomodori crescono vicini o lungo linee oblique, i loro rettangoli di delimitazione finiscono per sovrapporsi, facendo credere al sistema che i frutti siano coperti tra loro anche quando in realtà sono completamente liberi.

Questa imprecisione geometrica rende molto complessa la gestione delle occlusioni reciproche, ovvero capire quale frutto si trovi davanti e quale dietro rispetto alla telecamera. Se il robot tentasse di raccogliere un pomodoro senza considerare chi lo copre frontalmente, la pinza di presa andrebbe a urtare i frutti antistanti, danneggiandoli. Inoltre, all'interno dello stesso grappolo sono spesso presenti pomodori ancora verdi: se un frutto acerbo si trova davanti a uno maturo, agisce come un ostacolo fisico che impedisce l'accesso al frutto rosso.

²A. Silwal et al., «Design, Integration, and Field Evaluation of a Robotic Apple Harvester,» *Journal of Field Robotics*, vol. 34, n. 6, pp. 1140–1159, 2017. DOI: 10.1002/rob.21715

Infine, la raccolta di un grappolo non può essere pianificata in un colpo solo in modo statico. La rimozione fisica di un pomodoro modifica immediatamente la scena: togliere il primo frutto frontale libera spazio e permette di raggiungere i pomodori retrostanti che prima erano coperti. Per evitare collisioni e raccogliere i frutti nell'ordine corretto, è quindi necessario superare l'approssimazione dei rettangoli rigidi e sviluppare una strategia decisionale dinamica, capace di stimare i contatti reali e di aggiornare la sequenza di raccolta a ogni singolo prelievo.

1.3 Obiettivi della Tesi

L'obiettivo principale di questo lavoro di tesi è progettare, implementare e validare una pipeline decisionale per stimare le occlusioni e pianificare la sequenza di raccolta dei pomodori in serra, superando i limiti delle tradizionali *bounding box* attraverso una modellazione geometrica basata su ellissi orientate.

Nello specifico, il lavoro si articola sui seguenti obiettivi:

- **Modellazione geometrica con Convex Hull ed ellissi:** elaborare le maschere fornite dal modello di segmentazione YOLO11-x regolarizzandone i contorni tramite l'involucro convesso e adattarvi un'ellisse orientata, eliminando lo spazio vuoto negli angoli e stimando la reale inclinazione del frutto;
- **Screening e filtro di maturità:** valutare la raggiungibilità geometrica dei pomodori (tramite area visibile, circolarità e centralità), eliminare le predizioni duplicate e distinguere i frutti maturi da quelli acerbi tramite l'analisi del colore nello spazio HSV, considerando i pomodori verdi come ostacoli da non urtare;
- **Task planning dinamico *Pick & Update*:** sviluppare un algoritmo che simula il prelievo del frutto a ogni passo e aggiorna lo stato della scena, premiando con un bonus di sblocco i pomodori retrostanti appena liberati;
- **Validazione sperimentale e confronto:** testare l'algoritmo su immagini reali di serra con grappoli densi, confrontando le scelte del nostro modello sia con una baseline a rettangoli rigidi sia con le decisioni prese da operatori umani.

Capitolo 2

Stato dell'Arte

L'applicazione della computer vision in agricoltura ha conosciuto una rapida evoluzione negli ultimi anni, passando da semplici algoritmi basati sul colore a modelli avanzati di deep learning capaci di interpretare scene complesse. Questo capitolo esamina lo stato dell'arte delle tecnologie di visione per la raccolta robotizzata, partendo dall'evoluzione dei modelli di rilevamento e segmentazione fino ad analizzare le tecniche proposte in letteratura per affrontare il problema delle occlusioni nei grappoli densi.

2.1 Computer Vision per l'Agricoltura di Precisione

I primi tentativi di applicare la visione artificiale alla raccolta automatizzata risalgono a diversi decenni fa e si basavano su tecniche classiche di elaborazione delle immagini [1]¹. Questi approcci tradizionali utilizzavano principalmente la segmentazione per soglia cromatica (ad esempio negli spazi colore RGB o HSV), filtri morfologici per pulire il rumore di fondo e semplici algoritmi geometrici per l'analisi dei contorni.

Tuttavia, questi metodi mostravano limiti evidenti nelle condizioni reali di una serra. La segmentazione basata sul colore funzionava solo in laboratorio sotto luce artificiale stabile, mentre all'interno della serra la luce solare cambia continuamente durante la giornata, mandando in crisi le soglie fisse. Il problema principale riguardava la forte somiglianza cromatica tra i pomodori acerbi e la vegetazione circostante: le foglie e i frutti verdi condividono tonalità quasi identiche, rendendo impossibile distinguerli affidandosi al solo colore. Inoltre, le tecniche tradizionali non erano in grado di gestire le frequenti sovrapposizioni tra frutti, finendo spesso per considerare interi grappoli come un'unica sagoma indistinta.

¹A. Gongal et al., «Sensors and Systems for Fruit Detection and Localization: A Review,» *Computers and Electronics in Agriculture*, vol. 116, pp. 8–19, 2015. DOI: 10.1016/j.compag.2015.05.021

La svolta è arrivata con l'introduzione del *Deep Learning* e in particolare delle reti neurali convoluzionali (CNN). A differenza degli approcci classici, in cui le regole per riconoscere un frutto dovevano essere scritte a mano, le reti neurali sono capaci di apprendere autonomamente le caratteristiche visive a partire dalle immagini fornite durante l'addestramento. Il modello impara così a combinare informazioni di colore, bordi, sfumature e contesto della scena. Questo cambio di paradigma ha permesso di riconoscere i pomodori anche in presenza di forti variazioni di luce, ombre fitte e grappoli molto densi, gettando le basi percettive per i moderni sistemi di raccolta robotizzata.

2.2 Rilevamento e Segmentazione delle Istanze

All'interno delle tecniche di deep learning per la visione artificiale, i modelli per la localizzazione degli oggetti si dividono storicamente in due grandi categorie: gli approcci a due stadi (come la famiglia R-CNN [3]²), che prima generano regioni candidate e poi le classificano, e i modelli a singolo stadio (*single-stage*), tra cui spicca l'architettura YOLO (*You Only Look Once*) [4]³.

I modelli YOLO hanno introdotto una vera e propria rivoluzione nel settore: invece di spezzare l'elaborazione in fasi separate, una singola rete neurale elabora l'immagine in un unico passaggio, producendo direttamente le coordinate degli oggetti e le relative classi. Questa caratteristica garantisce una velocità di esecuzione molto elevata, rendendo l'algoritmo adatto a funzionare in tempo reale a bordo di sistemi robotici.

Nel campo della raccolta robotizzata, è fondamentale distinguere tra due diversi compiti di visione che i modelli YOLO moderni possono svolgere:

- **Object Detection:** il modello localizza ciascun oggetto presente nella scena racchiudendolo all'interno di una *bounding box* rettangolare, a cui associa una classe e un punteggio di confidenza. Questo approccio è molto rapido, ma per sua natura approssimato: il rettangolo indica la presenza del pomodoro ma include anche porzioni di sfondo, rami e foglie, senza fornire alcuna informazione sulla sagoma reale del frutto.
- **Instance Segmentation:** rappresenta un'estensione più avanzata, in cui il modello non si limita a disegnare un rettangolo, ma assegna un'etichetta a ogni singolo pixel, producendo una maschera binaria che ritaglia la forma esatta di ciascun pomodoro

²K. He et al., «Mask R-CNN,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, n. 2, pp. 386–397, 2020. DOI: 10.1109/TPAMI.2018.2844175

³J. Redmon et al., «You Only Look Once: Unified, Real-Time Object Detection,» in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91

[5]⁴. In un'applicazione di raccolta robotica, disporre della maschera a livello di pixel è indispensabile: consente di distinguere pomodori a stretto contatto, calcolarne con precisione il centroide e delimitare i margini fisici necessari per posizionare correttamente l'organo di presa.

All'interno del progetto di ricerca del nostro laboratorio, la prima fase del lavoro è stata dedicata proprio allo studio, all'addestramento e all'ottimizzazione di questi modelli percettivi su un dataset acquisito in serra [6]⁵. Da tale indagine comparativa è emerso che il modello **YOLO11-x** (nella sua configurazione per l'Instance Segmentation) garantisce il miglior compromesso tra accuratezza metrica e qualità delle maschere prodotte, riuscendo a distinguere con efficacia i pomodori anche in presenza di fogliame fitto.

Tuttavia, disporre delle maschere di segmentazione fornite da YOLO costituisce solo il primo passo. La rete neurale si limita a dire "dove si trovano i pomodori", ma non fornisce alcuna informazione su come essi interagiscano nello spazio tridimensionale, chi copra chi e quale debba essere l'ordine di raccolta. È esattamente su questo divario che si innesta il presente lavoro di tesi.

2.3 Tecniche di Gestione delle Occlusioni in Letteratura

La gestione delle occlusioni reciproche all'interno di grappoli densi rappresenta uno degli aspetti più complessi nella robotica agricola [7]⁶. Quando i frutti crescono a stretto contatto, determinare quale pomodoro si trovi davanti agli altri e stabilire un ordine corretto di raccolta è indispensabile per consentire all'organo di presa di operare in sicurezza senza rischiare di danneggiare i frutti circostanti [2]⁷.

All'interno dell'architettura complessiva sviluppata nel nostro laboratorio, l'obiettivo applicativo a lungo termine prevede l'impiego di una telecamera RGB-D montata direttamente sul braccio meccanico (*eye-in-hand*), così da guidare il manipolatore verso il target combinando l'informazione visiva con la stima della distanza [6]⁸. Tuttavia, i dati raccolti

⁴G. Liu et al., «YOLO-Tomato: A Robust Algorithm for Tomato Detection Based on YOLOv3,» *Sensors*, vol. 20, n. 7, p. 2145, 2020. DOI: 10.3390/s20072145

⁵A. Collega, «Analisi comparativa di modelli YOLO per il rilevamento e la segmentazione del pomodoro nell'ambito dell'agricoltura di precisione per la raccolta robotizzata,» Tesi di Laurea Triennale, Università degli Studi di Milano, 2025

⁶C. W. Bac et al., «Harvesting Robots for High-Value Crops: State-of-the-Art Review and Challenges Ahead,» *Journal of Field Robotics*, vol. 31, n. 6, pp. 888–911, 2014. DOI: 10.1002/rob.21525

⁷A. Silwal et al., «Design, Integration, and Field Evaluation of a Robotic Apple Harvester,» *Journal of Field Robotics*, vol. 34, n. 6, pp. 1140–1159, 2017. DOI: 10.1002/rob.21715

⁸A. Collega, «Analisi comparativa di modelli YOLO per il rilevamento e la segmentazione del pomodoro nell'ambito dell'agricoltura di precisione per la raccolta robotizzata,» Tesi di Laurea Triennale, Università degli Studi di Milano, 2025

sul campo in serra e messi a disposizione per la fase di addestramento dei modelli percettivi consistevano esclusivamente in immagini a colori bidimensionali (RGB). Inoltre, la letteratura scientifica evidenzia come l'elaborazione diretta di nuvole di punti 3D in ambiente agricolo presenti sensibili criticità: i sensori di profondità risentono delle variazioni di illuminazione solare tipiche delle serre, la vegetazione sottile introduce rumore geometrico e gli algoritmi di ricostruzione volumetrica richiedono un carico computazionale elevato, difficilmente sostenibile durante i cicli di controllo rapido del braccio [1], [7]⁹. Si è quindi reso necessario concentrare questo lavoro di tesi sullo sviluppo di un modulo decisionale che operi interamente sul piano bidimensionale delle immagini RGB, estraendo la gerarchia spaziale delle occlusioni prima di inviare il punto di mira all'attuatore.

Sul piano bidimensionale, il primissimo approccio che abbiamo sviluppato insieme al collega nella fase iniziale del lavoro — subito dopo aver completato l'addestramento del modello YOLO — è consistito nel valutare le occlusioni sfruttando direttamente i riquadri di delimitazione rettangolari (*bounding box*) forniti nativamente dalla rete, in linea con diversi lavori preliminari presenti in letteratura [8]¹⁰. Tuttavia, l'applicazione pratica di questa prima soluzione ha mostrato fin da subito un grave limite geometrico: i pomodori hanno una conformazione curvilinea, per cui i quattro angoli della scatola rettangolare racchiudono una percentuale consistente di spazio vuoto. Quando due frutti si trovano vicini o disposti lungo linee diagonali, le rispettive *bounding box* finiscono per sovrapporsi vistosamente anche se i corpi dei pomodori non sono affatto a contatto. Questo fenomeno genera falsi blocchi geometrici, inducendo il sistema a considerare occlusi pomodori che nella realtà sarebbero perfettamente liberi e accessibili.

In letteratura, alcuni studi hanno proposto di ridurre queste imprecisioni ricorrendo all'involucro convesso (*Convex Hull*) per regolarizzare i contorni dei frutti [9]¹¹ o all'approssimazione mediante ellissi orientate [10]¹². Tuttavia, la maggior parte di queste indagini si è concentrata principalmente sulla ricostruzione morfologica del singolo frutto isolato, senza sviluppare un algoritmo decisionale completo per stabilire la sequenza ottima di prelievo.

Un ulteriore limite comune a gran parte dei metodi esistenti risiede nella natura statica della pianificazione. Nella quasi totalità dei casi, l'ordine di raccolta viene calcolato in un

⁹A. Gongal et al., «Sensors and Systems for Fruit Detection and Localization: A Review,» *Computers and Electronics in Agriculture*, vol. 116, pp. 8–19, 2015. doi: 10.1016/j.compag.2015.05.021 C. W. Bac et al., «Harvesting Robots for High-Value Crops: State-of-the-Art Review and Challenges Ahead,» *Journal of Field Robotics*, vol. 31, n. 6, pp. 888–911, 2014. doi: 10.1002/rob.21525

¹⁰X. Chen e S. X. Yang, «A practical solution for ripe tomato recognition and localisation,» *Journal of Real-Time Image Processing*, vol. 8, n. 1, pp. 35–51, 2013. doi: 10.1007/s11554-011-0222-9

¹¹Y. Changhui et al., «Reconstruction Method of Overlapped Citrus Fruits in Natural Scenes Based on Convex Hull,» in *Proceedings of the International Conference on Computer Systems, Electronics and Control (ICCSEC)*, IEEE, 2017, pp. 1095–1098. doi: 10.1109/ICCSEC.2017.8447005

¹²S. Wang e T. Luo, «A Multi-Fruit Recognition Method for a Fruit-Harvesting Robot Using MSA-Net and Hough Transform Elliptical Detection Compensation,» *Horticulturae*, vol. 10, n. 10, p. 1024, 2024. doi: 10.3390/horticulturae10101024

unico passaggio iniziale, ordinando i pomodori in base alla sola visibilità o alla distanza. Questo approccio ignora la dinamica fisica dell'operazione di raccolta: il prelievo del primo pomodoro frontale modifica immediatamente la scena, liberando lo spazio di manovra e rendendo accessibili i frutti retrostanti che in precedenza risultavano bloccati.

Il presente lavoro di tesi nasce esattamente dalla necessità di superare il nostro approccio iniziale a *bounding box* e le limitazioni dei metodi statici. L'obiettivo è proporre una pipeline 2D leggera e deterministica che, operando sulle maschere di segmentazione di YOLO11-x, utilizzi il Convex Hull per ripulire le imperfezioni, modelli i frutti tramite ellissi orientate e introduca un algoritmo dinamico (*Pick & Update*) capace di ricalcolare le priorità a ogni prelievo simulato. Nel capitolo successivo verrà descritta nel dettaglio la formulazione matematica e l'architettura completa di questa metodologia.

Capitolo 3

Metodologia e Pipeline Decisionale

All'interno di una serra reale, la sola identificazione visiva dei pomodori non basta per guidare un braccio robotico: la forte densità dei grappoli e il fogliame creano continue sovrapposizioni tra i frutti, rendendo critico capire quale pomodoro raccogliere per primo senza rischiare urti con la pinza.

Per colmare il divario tra la segmentazione delle immagini e l'azione fisica del manipolatore, è stata sviluppata una pipeline decisionale articolata in quattro stadi operativi:

1. **Modellazione geometrica:** stima della forma e dell'orientamento dei pomodori tramite ellissi fittate sull'involucro convesso (*Convex Hull*), superando le limitazioni delle *bounding box*;
2. **Screening e scoring:** esclusione dei frutti con area inferiore alla soglia minima e assegnazione di un punteggio geometrico combinato (area visibile, circolarità e centralità);
3. **Filtro di maturità:** separazione dei pomodori maturi da quelli acerbi tramite soglia di maturità nello spazio colore HSV, trattando i frutti verdi come ostacoli statici;
4. **Depth ordering e task planning:** stima delle occlusioni mutue tramite sovrapposizione tra ellissi e determinazione iterativa della sequenza di prelievo (*Pick & Update*).

La struttura complessiva della pipeline decisionale e l'interazione tra i singoli moduli computazionali sono illustrate nel diagramma a blocchi di Figura 1.




Figura 1: Schema a blocchi della pipeline decisionale: dall'immagine RGB acquisita in serra alla sequenza ordinata di raccolta per il manipolatore robotico.

3.1 Limiti delle Bounding Box e Modellazione Ellittica con Convex Hull

A partire da ciascuna immagine acquisita in serra, il modello di Instance Segmentation (YOLOv11-seg) individua i pomodori presenti nella scena, restituendo per ciascun frutto rilevato una tupla:

$$\mathcal{D}_i = (B_i, \mathcal{M}_i, c_i) \quad (1)$$

dove $B_i = [x_1, y_1, x_2, y_2]$ identifica le coordinate della *bounding box* assiale, $\mathcal{M}_i \in \{0, 1\}^{H \times W}$ è la maschera binaria dei pixel appartenenti all'istanza e $c_i \in [0, 1]$ rappresenta il livello di confidenza associato alla predizione.

3.1.1 Limiti Geometrici delle Bounding Box Assiali

Nel campo della visione artificiale, l'approccio standard per localizzare gli oggetti si basa sulle *bounding box* allineate agli assi dell'immagine (*Axis-Aligned Bounding Box*, AABB) [4]¹. Tuttavia, nei sistemi di raccolta robotizzata di frutti aggregati in grappoli compatti [8]², l'impiego dei soli riquadri rettangolari evidenzia un limite geometrico strutturale. I pomodori possiedono una sagoma curvilinea, mentre la bounding box è un rettangolo rigido vincolato all'orientamento orizzontale e verticale. Considerando, a titolo esemplificativo, un frutto con proiezione circolare di raggio r , l'area effettiva del pomodoro è πr^2 , a fronte di un'area del rettangolo circoscritto pari a $(2r)^2 = 4r^2$. Il rapporto tra le due superfici risulta:


$$\frac{\pi r^2}{4r^2} = \frac{\pi}{4} \approx 0.785 \quad (2)$$

Questo implica che oltre il 21.5% dell'area di ogni bounding box è costituito da spazio vuoto (sfondo, foglie o rami circostanti). Quando i frutti crescono ravvicinati o disposti lungo linee diagonali, i rettangoli di delimitazione finiscono per intersecarsi vistosamente nelle zone angolari prive di frutto. Tale sovrapposizione fittizia impedisce una stima fedele del contatto reale: due frutti adiacenti ma perfettamente liberi verrebbero considerati geometricamente sovrapposti solo a causa dell'ingombro degli angoli del rettangolo, come evidenziato nel confronto di Figura 2. Questo limite rende indispensabile superare l'approssimazione rettangolare a favore di una modellazione continua e aderente alla sagoma reale del frutto [5]³.

¹J. Redmon et al., «You Only Look Once: Unified, Real-Time Object Detection,» in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91

²X. Chen e S. X. Yang, «A practical solution for ripe tomato recognition and localisation,» *Journal of Real-Time Image Processing*, vol. 8, n. 1, pp. 35–51, 2013. DOI: 10.1007/s11554-011-0222-9

³G. Liu et al., «YOLO-Tomato: A Robust Algorithm for Tomato Detection Based on YOLOv3,» *Sensors*, vol. 20, n. 7, p. 2145, 2020. DOI: 10.3390/s20072145



(a) Falso positivo indotto dall'intersezione angolare delle ABBB.



(b) Modellazione con ellissi orientate: contatto reale e assenza di sovrapposizione spuria.

Figura 2: Confronto geometrico su frutti adiacenti in diagonale: i limiti delle bounding box assiali (a) e la risoluzione tramite fitting ellittico (b).

3.1.2 Modellazione tramite Convex Hull e Fitting Ellittico

Per superare le limitazioni delle bounding box senza ricorrere a calcoli onerosi sulle maschere dense, ciascun pomodoro viene approssimato tramite un'ellisse orientata nel piano immagine. L'ellisse costituisce il compromesso ottimale: racchiude la curvatura del frutto, ne stima le proporzioni assiali e ne individua l'inclinazione, eliminando lo spazio vuoto angolare dei rettangoli [10]⁴. Il processo di modellazione geometrica si articola in tre passaggi consecutivi:

1. **Estrazione della nuvola di pixel:** a partire dalla maschera binaria $\mathcal{M}_i$, vengono estratte le coordinate di tutti i pixel attivi:

$$\mathcal{P}_i = \{(u, v) \in \mathbb{N}^2 \mid \mathcal{M}_i(u, v) = 1\} \quad (3)$$

L'estrazione globale delle coordinate (anziché il tracciamento di un singolo contorno) conferisce robustezza nei confronti di eventuali frammentazioni della maschera, ad esempio quando un ramo sottile suddivide la segmentazione di un singolo frutto in più isole disgiunte. Matematicamente, l'identificazione univoca dei parametri di

⁴S. Wang e T. Luo, «A Multi-Fruit Recognition Method for a Fruit-Harvesting Robot Using MSA-Net and Hough Transform Elliptical Detection Compensation,» *Horticulturae*, vol. 10, n. 10, p. 1024, 2024. doi: 10.3390/horticulturae10101024

una conica richiede almeno 5 punti non degeneri; la stabilità statistica del fitting viene comunque garantita dal vincolo di area minima ($A_i \geq 1500$ pixel) descritto nella sezione successiva.

2. **Calcolo dell'involucro convesso (*Convex Hull*)**: le maschere generate dalla rete possono presentare piccole concavità o irregolarità di bordo causate da ombre, foglie sottili o dal calice. L'algoritmo determina l'involucro convesso $\mathcal{H}_i$ congiungendo i vertici più esterni della nuvola $\mathcal{P}_i$, colmando tali rientranze spurie e regolarizzando la sagoma prima del fitting [9]⁵.
3. **Adattamento dell'ellisse (*Fit Ellipse*)**: sui vertici dell'involucro convesso viene applicato l'adattamento algebrico basato sul metodo dei minimi quadrati diretti [11]⁶. L'algoritmo restituisce una rappresentazione compatta definita da cinque parametri geometrici:

$$\mathcal{E}_i = ((x_{c,i}, y_{c,i}), (d_{\min,i}, d_{\max,i}), \theta_i) \quad (4)$$

dove $(x_{c,i}, y_{c,i})$ rappresenta il centroide, $d_{\min,i}$ e $d_{\max,i}$ corrispondono rispettivamente alle lunghezze dell'asse minore e maggiore, e $\theta_i \in [0^\circ, 180^\circ)$ indica l'angolo di inclinazione dell'asse principale rispetto all'orizzontale.

Rilevanza dell'angolo di inclinazione θ Oltre a delimitare con precisione la sagoma del frutto, il parametro θ_i riveste un ruolo chiave per l'integrazione robotica: fornisce l'informazione necessaria per orientare la pinza di presa (*gripper*) lungo la direzione naturale di accrescimento del pomodoro, favorendo un prelievo pulito e riducendo le sollecitazioni meccaniche sul peduncolo.

3.2 Screening Dimensionale e Metriche di Raggiungibilità

Tra le predizioni restituite dal modello possono essere presenti rilevazioni spurie, come falsi positivi generati da riflessi o frammenti di foglie, oppure pomodori sullo sfondo troppo distanti per l'interazione robotica. Per ripulire l'output, la pipeline calcola

⁵Y. Changhui et al., «Reconstruction Method of Overlapped Citrus Fruits in Natural Scenes Based on Convex Hull,» in *Proceedings of the International Conference on Computer Systems, Electronics and Control (ICCSEC)*, IEEE, 2017, pp. 1095–1098. DOI: 10.1109/ICCSEC.2017.8447005

⁶A. Fitzgibbon et al., «Direct least squares fitting of ellipses,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 21, n. 5, pp. 476–480, 1999. DOI: 10.1109/34.765658

preliminarmente l'area in pixel A_i di ciascuna maschera sommando tutti i pixel attivi:

$$A_i = \sum_{u=1}^W \sum_{v=1}^H \mathcal{M}_i(u, v) \quad (5)$$

Viene quindi imposto un vincolo di ammissibilità dimensionale basato su una soglia minima $A_{\min}$:

$$A_i \geq A_{\min} \quad (6)$$

avendo fissato $A_{\min} = 1500$ pixel. Tutti i candidati con area inferiore a tale soglia vengono scartati a monte dell'elaborazione.

La scelta di $A_{\min}$ è stata determinata empiricamente analizzando le immagini acquisite in serra. Dal punto di vista geometrico, per una sagoma approssimativamente circolare, un'area di 1500 pixel corrisponde a un diametro apparente di circa 44 pixel. Tale soglia costituisce un compromesso operativo efficace: da un lato elimina le false rilevazioni su frammenti vegetativi e i frutti distanti sullo sfondo, dall'altro evita di escludere pomodori in primo piano parzialmente coperti, assicurando al contempo un numero di pixel sufficiente a rendere stabile il calcolo dell'involucro convesso e dei descrittori di forma.

3.2.1 Metriche di Valutazione Geometrica

I candidati che superano il vincolo di area minima vengono valutati mediante tre indici geometrici adimensionali e normalizzati nell'intervallo $[0, 1]$, ideati per quantificare la raggiungibilità del target da parte del manipolatore robotico:

1. Area Normalizzata (A_{norm}) In ottica prospettica, i frutti più vicini al punto di ripresa e meno coperti da ostacoli occupano una superficie maggiore nel fotogramma. Assumendo come target di riferimento ideale un frutto la cui proiezione copra almeno il 15% della superficie totale dell'immagine ($0.15 \cdot W \cdot H$), l'indice viene calcolato imponendo una funzione di saturazione unitaria:

$$A_{\text{norm},i} = \min \left(1.0, \frac{A_i}{0.15 \cdot W \cdot H} \right) \quad (7)$$

Target in primo piano con estensione $\geq 15\%$ ottengono il punteggio massimo (1.0), mentre rilevazioni più lontane o parzialmente coperte ricevono punteggi proporzionalmente decrescenti.

2. Circolarità (Φ) Un pomodoro isolato e privo di ostacoli presenta una sagoma tondeggiante e compatta, mentre la presenza di rami o peduncoli occludenti ne frammenta la proiezione visibile. Per evitare che le irregolarità e le concavità del contorno pixelato

diretto alterino la stima, il perimetro P_i viene calcolato direttamente sull'involucro convesso $\mathcal{H}_i$ introdotto in precedenza, preservando la consistenza geometrica del descrittore di forma anche in presenza di elementi occludenti lineari [12]⁷. L'indice di circolarità Φ_i viene calcolato mediante il descrittore standard di compattezza basato sul rapporto area-perimetro:

$$\Phi_i = \min \left(1.0, \frac{4\pi A_i}{P_i^2} \right) \quad (8)$$

Questa formulazione svolge un ruolo duplice: premia le sagome con profilo circolare e, al contempo, penalizza i frutti parzialmente coperti da rametti sottili, nei quali l'area visibile A_i si riduce a parità di perimetro convesso.

3. Centralità Ottica (C) Questo descrittore favorisce i frutti localizzati in prossimità del centro del fotogramma $(W/2, H/2)$, dove le distorsioni ottiche della lente sono minime e il rischio che il frutto sia parzialmente tagliato fuori dall'inquadratura si azzera. Il baricentro $(c_{x,i}, c_{y,i})$ viene ricavato come media aritmetica delle coordinate dei pixel attivi:

$$c_{x,i} = \frac{1}{A_i} \sum_{(u,v) \in \mathcal{M}_i} u, \quad c_{y,i} = \frac{1}{A_i} \sum_{(u,v) \in \mathcal{M}_i} v \quad (9)$$

La distanza dal centro viene quindi normalizzata rispetto alla semidiagonale massima del fotogramma $d_{\max} = \sqrt{(W/2)^2 + (H/2)^2}$:

$$C_i = 1.0 - \frac{\sqrt{(c_{x,i} - W/2)^2 + (c_{y,i} - H/2)^2}}{d_{\max}} \quad (10)$$

L'indice premia i frutti situati nella zona centrale dell'immagine, dove si riduce il rischio di considerare elementi parzialmente tagliati fuori dai bordi del fotogramma e l'analisi geometrica risulta più robusta.

3.2.2 Punteggio Geometrico Combinato

I tre descrittori geometrici vengono aggregati mediante una combinazione lineare pesata sotto il vincolo di normalizzazione $\sum_k w_k = w_a + w_\phi + w_c = 1.0$, ottenendo lo score geometrico globale $G_i \in [0, 1]$:

$$G_i = w_a A_{\text{norm},i} + w_\phi \Phi_i + w_c C_i \quad (11)$$

I coefficienti di ponderazione adottati sono riportati in Tabella 1.

⁷J. D. Žunić e P. L. Rosin, «A New Convexity Measure for Polygons,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, n. 7, pp. 923–934, 2004. DOI: 10.1109/TPAMI.2004.19

Tabella 1: Pesi assegnati alle caratteristiche geometriche.

Indice	Simbolo	Peso	Motivazione
Area normalizzata	w_a	0.45	Favorisce i frutti più vicini e con superficie sgombra
Circolarità	w_ϕ	0.35	Premia sagome integre e non coperte da rami sottili
Centralità ottica	w_c	0.20	Favorisce target ben centrati rispetto all'obiettivo

Il punteggio G_i quantifica l'accessibilità visiva e la regolarità morfologica di ciascuna istanza rilevata. Tuttavia, la sola idoneità geometrica non è sufficiente per definire i target operativi: nei grappoli complessi occorre prima depurare le predizioni dai falsi duplicati e accertare lo stato di maturazione biologica dei frutti.

3.3 Deduplicazione, Selezione del Pool e Filtro di Maturità

Le rilevazioni fornite dalla rete neurale vengono elaborate attraverso tre stadi di filtraggio e selezione. Il primo stadio elimina le rilevazioni duplicate dello stesso frutto confrontando le maschere di segmentazione. Il secondo stadio ordina i pomodori in base al punteggio geometrico ed estrae un gruppo ristretto di candidati, così da contenere il numero di confronti da effettuare. Il terzo stadio valuta la maturazione di ciascun frutto analizzando la componente cromatica nello spazio HSV, distinguendo i pomodori maturi da quelli ancora verdi.

3.3.1 Deduplicazione con Mask-IoU

Nei grappoli densi, la rete neurale può generare rilevazioni multiple per la medesima istanza fisica. Se non rimossi, duplicati con punteggio geometrico elevato occuperebbero indebitamente posizioni primarie nella graduatoria di raccolta.

Per ovviare a questo problema, le rilevazioni che hanno superato il filtro di area minima vengono ordinate in senso decrescente in base alla confidenza del modello ($c_{(1)} \geq c_{(2)} \geq \dots \geq c_{(N)}$). Scorrendo tale sequenza, ciascuna maschera candidata viene confrontata con quelle già validate mediante l'indice IoU (*Intersection over Union*) calcolato a livello di pixel:

$$\text{IoU}(\mathcal{M}_i, \mathcal{M}_j) = \frac{\sum_{u=1}^W \sum_{v=1}^H (\mathcal{M}_i(u, v) \wedge \mathcal{M}_j(u, v))}{\sum_{u=1}^W \sum_{v=1}^H (\mathcal{M}_i(u, v) \vee \mathcal{M}_j(u, v))} \quad (12)$$

Se l'intersezione supera la soglia $\tau_{\text{dedup}} = 0.70$, l'istanza con confidenza minore viene rigettata come duplicato. L'adozione del Mask-IOU è cruciale rispetto alla soppressione dei non massimi basata su riquadri rettangolari: frutti adiacenti e a contatto presentano sovente forti sovrapposizioni a livello di bounding box pur costituendo corpi distinti, che il controllo pixel-wise preserva correttamente.

3.3.2 Selezione del Pool di Candidati

A valle della deduplicazione, i pomodori rimasti vengono ordinati in senso decrescente secondo lo score geometrico G_i . Per contenere i tempi di calcolo ed evitare di analizzare combinazioni inutili sui frutti marginali, la pipeline estrae un gruppo ristretto limitato ai primi $K = 8$ candidati, definito come $\mathcal{P}_{\text{geo}} = \{\mathcal{D}_{(1)}, \mathcal{D}_{(2)}, \dots, \mathcal{D}_{(K)}\}$. Questa scelta riduce il numero di coppie da verificare nella successiva stima delle occlusioni a un massimo di $K(K - 1) = 56$ confronti, mantenendo l'elaborazione rapida e adatta al ciclo di controllo del manipolatore robotico.

3.3.3 Analisi del Colore nello Spazio HSV e Indice di Maturità

Un pomodoro facilmente raggiungibile non deve essere raccolto se non ha ancora raggiunto la corretta maturazione commerciale [13], [14]⁸. Per rendere il controllo del colore meno sensibile alle ombre e ai riflessi tipici della luce in serra, l'immagine RGB viene convertita nello spazio colore HSV (*Hue, Saturation, Value*), in cui la tinta pura (H) è separata dalla luminosità (V).

Nello spazio HSV di OpenCV, il colore rosso si trova distribuito a cavallo dell'origine della scala ($[0, 180]$). L'intervallo associato al rosso maturo viene quindi definito dall'unione di due intervalli:

$$\mathcal{R}_{\text{red}} = (H \in [0, 15] \cup [165, 180]) \quad \text{con } S \geq 50, V \geq 50 \quad (13)$$

Mentre la fascia associata al verde dei frutti acerbi è delimitata da:

$$\mathcal{R}_{\text{green}} = (H \in [35, 85]) \quad \text{con } S \geq 40, V \geq 40 \quad (14)$$

Le soglie minime su saturazione e luminosità servono a scartare sia le zone sovraesposte dai riflessi solari sia quelle troppo in ombra. Per ciascuna maschera $\mathcal{M}_i$, si conta quanti pixel ricadono nella fascia del rosso ($N_{\text{red},i}$) e quanti in quella del verde ($N_{\text{green},i}$), ricavando

⁸A. Ahmad et al., «Comparative Analysis of R-CNN and YOLOv8 Segmentation Features for Tomato Ripening Stage Classification and Quality Estimation,» *Horticulturae*, vol. 12, n. 2, p. 127, 2026. DOI: 10.3390/horticulturae12020127 B. Xiao et al., «Fruit ripeness identification using YOLOv8 model,» *Multimedia Tools and Applications*, vol. 83, n. 11, pp. 33 737–33 754, 2024. DOI: 10.1007/s11042-023-16570-9

l'indice di maturità continuo $M_i \in [0, 1]$:

$$M_i = \begin{cases} \frac{N_{\text{red},i}}{N_{\text{red},i} + N_{\text{green},i}} & \text{se } (N_{\text{red},i} + N_{\text{green},i}) > 0 \\ 0.0 & \text{altrimenti} \end{cases} \quad (15)$$

Un pomodoro viene considerato pronto per la raccolta solo se supera la soglia $M_i \geq \tau_{\text{mat}} = 0.50$.

I frutti acerbi come ostacoli statici Un dettaglio fondamentale dell'algoritmo riguarda la gestione dei pomodori acerbi ($M_i < \tau_{\text{mat}}$), che non vengono scartati dalla scena. Se un pomodoro verde si trova posizionato davanti a uno rosso, ne ostruisce fisicamente l'accesso: se il sistema lo ignorasse, il robot tenterebbe di afferrare il frutto maturo andando a urtare quello verde. I pomodori acerbi vengono pertanto mantenuti nel calcolo con il ruolo di **ostacoli statici non rimovibili**: non possono essere raccolti, ma servono a segnalare che i frutti maturi retrostanti sono bloccati e non possono essere prelevati per primi.

3.4 Risoluzione del Depth Ordering e Mappa delle Occlusioni

Una volta modellate le sagome dei pomodori mediante ellissi orientate, occorre stabilire se tra i candidati del pool vi siano sovrapposizioni e determinare quale frutto si trovi davanti all'altro rispetto alla telecamera. Per quantificare la sovrapposizione tra due pomodori i e j , l'algoritmo renderizza le rispettive ellissi piene $\mathcal{E}_i$ e $\mathcal{E}_j$ su due immagini binarie temporanee e ne calcola l'intersezione tramite un'operazione AND logica a livello di pixel:

$$\mathcal{I}_{ij} = \mathcal{E}_i \cap \mathcal{E}_j \quad (16)$$

Il grado di sovrapposizione viene quindi valutato rispetto all'area dell'ellisse del frutto i :

$$\rho_{ij} = \frac{|\mathcal{I}_{ij}|}{|\mathcal{E}_i|} \quad (17)$$

dove $|\cdot|$ indica il conteggio dei pixel attivi. Se questo rapporto supera la soglia minima $\tau_{\text{occ}} = 0.15$ (15%), si conclude che tra i due frutti esiste una sovrapposizione non trascurabile.

Nelle immagini bidimensionali la sola intersezione geometrica non consente di distinguere quale frutto si trovi più vicino all'obiettivo e quale sia retrostante. Per risolvere

questo ordinamento in profondità senza ricorrere a sensori 3D, si sfrutta la naturale omogeneità di calibro dei pomodori dello stesso grappolo: il frutto in primo piano conserva quasi integra la propria sagoma, mentre quello retrostante ne mostra solo una porzione parziale. In presenza di sovrapposizione ($\rho_{ij} > \tau_{occ}$), si confrontano quindi le aree delle rispettive maschere binarie (A_i e A_j):

$$\text{Se } \rho_{ij} > \tau_{occ} \quad \text{e} \quad A_i < A_j \implies j \text{ blocca } i \quad (18)$$

Il frutto j viene così registrato come bloccante e l'istanza i viene inserita nel rispettivo insieme dei pomodori occlusi O_j . Questa regola si basa sull'ipotesi che i pomodori dello stesso grappolo abbiano dimensioni simili. Pur presentando dei limiti in alcuni casi particolari (ad esempio quando un frutto molto piccolo si trova davanti a uno nettamente più grande), nella maggior parte delle situazioni reali consente di identificare correttamente le relazioni di blocco con un costo computazionale trascurabile.

3.5 Algoritmo di Task Planning Dinamico

Una volta costruita la mappa delle occlusioni, occorre determinare la sequenza ordinata con cui raccogliere i frutti maturi. In un grappolo fitto, limitarsi a ordinare i bersagli secondo il punteggio geometrico iniziale non è sufficiente: prelevare un pomodoro che si trova davanti ad altri ne modifica immediatamente l'accessibilità visiva e fisica. Per simulare questo processo decisionale, l'algoritmo implementa un ciclo iterativo (paradigma *Pick & Update*) con l'obiettivo di selezionare una sequenza composta da un massimo di $N_{\max} = 3$ bersagli primari.

3.5.1 Penalizzazione delle Occlusioni e Punteggio Dinamico

A ogni iterazione del ciclo $k \in \{1, \dots, N_{\max}\}$, l'algoritmo prende in considerazione i soli frutti maturi non ancora raccolti, escludendo i pomodori acerbi che continuano a fungere da ostacoli nella scena. Per ciascuno di questi candidati, si verifica se nello stato corrente della scena vi siano ancora elementi bloccanti antistanti. Un frutto i viene considerato attualmente occluso se esiste almeno un altro pomodoro j (maturo o acerbo) non ancora raccolto che lo occlude direttamente ($i \in O_j$). In base a questo controllo, viene assegnato un coefficiente di penalità $p_i^{(k)}$:

$$p_i^{(k)} = \begin{cases} \gamma_{occ} = 0.70 & \text{se il frutto } i \text{ è attualmente occluso} \\ 1.0 & \text{se il frutto } i \text{ è libero frontalmente} \end{cases} \quad (19)$$

Il punteggio decisionale aggiornato $S_i^{(k)}$ viene quindi calcolato combinando lo score geometrico di base, la condizione istantanea di occlusione e l'eventuale moltiplicatore di sblocco $b_i^{(k)}$ maturato nelle iterazioni precedenti:

$$S_i^{(k)} = G_i \times p_i^{(k)} \times b_i^{(k)} \quad (20)$$

dove all'inizio del ciclo per tutti i frutti vale $b_i^{(1)} = 1.0$. L'algoritmo ordina quindi i candidati maturi e seleziona come miglior bersaglio del passo corrente quello che massimizza il punteggio finale:

$$d^* = \arg \max_i S_i^{(k)} \quad (21)$$

Il frutto d^* viene contrassegnato come prelevato e inserito al posto k della sequenza di raccolta.

3.5.2 Rimozione Virtuale e Meccanismo di Sblocco

Una volta selezionato il miglior bersaglio d^* al passo k , l'algoritmo simula la sua rimozione fisica dalla scena per aggiornare le condizioni operative delle iterazioni successive. L'aggiornamento dello stato avviene in due fasi:

1. **Aggiornamento dello stato di raccolta:** Il frutto d^* viene contrassegnato come selezionato ed estratto dall'insieme dei candidati disponibili. A partire dall'iterazione successiva, esso non rientra più tra i frutti estraibili e cessa di agire come ostacolo per il resto del grappolo.
2. **Propagazione del bonus di sblocco:** Per ciascun frutto u appartenente all'insieme di quelli direttamente occlusi da d^* ($u \in O_{d^*}$), il moltiplicatore di sblocco viene impostato al valore premiante:

$$b_u^{(k+1)} = \beta_{\text{unlock}} = 1.20 \quad (22)$$

All'iterazione successiva $k + 1$, l'effetto della rimozione virtuale produce una rilevante riconfigurazione dei punteggi decisionali:

- Se il frutto d^* era l'unico elemento a coprire frontalmente u , quest'ultimo risulterà ora privo di ostacoli attivi nella scena; di conseguenza, la penalità $p_u^{(k+1)}$ salirà da 0.70 a 1.0.

- Combinando la rimozione della penalità con il moltiplicatore $b_u^{(k+1)} = 1.20$, il punteggio complessivo del frutto liberato registra un incremento relativo pari a:

$$\frac{S_u^{(k+1)}}{S_u^{(k)}} = \frac{G_u \times 1.0 \times 1.20}{G_u \times 0.70 \times 1.0} \approx 1.714 \quad (+71.4\%) \quad (23)$$

Questo forte incentivo numerico fa sì che i pomodori immediatamente retrostanti a un frutto appena rimosso scalino rapidamente la graduatoria, orientando il pianificatore a disfare il grappolo partendo dagli strati più esterni verso quelli più interni.

- Se invece il frutto u rimane parzialmente occluso da un ulteriore pomodoro non ancora rimosso, la penalità $p_u^{(k+1)} = 0.70$ rimane attiva, ma il bonus 1.20 ne attenua comunque l'impatto portando il moltiplicatore effettivo da 0.70 a 0.84.

Il ciclo decisionale prosegue fino al raggiungimento della lunghezza massima della sequenza di prelievo ($N_{\max} = 3$) oppure fino all'esaurimento dei candidati maturi disponibili.

A scopo comparativo, l'algoritmo calcola contestualmente una sequenza statica di riferimento, ottenuta estraendo i primi 5 frutti maturi ordinati unicamente in base al punteggio geometrico G_i , senza applicare alcuna penalità per le occlusioni né aggiornamenti dinamici di stato. Tale sequenza (*baseline*) fungerà da termine di confronto per quantificare, in sede sperimentale, i vantaggi introdotti dal planning dinamico nella prevenzione delle collisioni.

Capitolo 4

Validazione Sperimentale e Discussione

In questo capitolo vengono presentati i risultati ottenuti testando la pipeline decisionale proposta nel Capitolo 3. L'obiettivo principale è verificare se la modellazione geometrica con ellissi e la pianificazione dinamica migliorino concretamente la scelta della sequenza di raccolta rispetto ai metodi tradizionali basati su *bounding box*.

Dapprima vengono descritte le immagini di test acquisite in serra e i parametri operativi della pipeline. Successivamente, l'efficacia del metodo viene valutata confrontando le decisioni dell'algoritmo con la baseline a riquadri rigidi e con le scelte di riferimento annotate da operatori umani. Infine, l'analisi di alcuni casi studio reali consente di esaminare da vicino come il sistema gestisce lo sblocco dei frutti occlusi e quali sono i principali limiti riscontrati.

4.1 Configurazione Sperimentale e Dataset di Test

La correttezza della pianificazione dipende direttamente dalla qualità delle maschere fornite dal modello di visione. Contorni rumorosi o frammentati alterano il calcolo dell'involucro convesso e dell'ellisse associata a ciascun frutto, inducendo stime errate delle occlusioni tra pomodori adiacenti. Definire con rigore le condizioni di acquisizione, la risoluzione di inferenza e le soglie geometriche costituisce quindi il presupposto necessario per isolare l'efficacia del planner e garantirne la riproducibilità.

4.1.1 Dataset e Immagini di Test

La sperimentazione è stata condotta a partire da un dataset acquisito in ambiente di serra, composto complessivamente da 1803 immagini con risoluzione nativa di 432×432

pixel. Le annotazioni poligonali comprendono quattro classi: frutti (*tomato*), fusto principale (*MainStem*), peduncoli (*peduncle*) e piccioli (*petiole*). Ai fini della raccolta, la pipeline sviluppata elabora esclusivamente le maschere appartenenti alla classe *tomato*.

Per la validazione della pipeline decisionale e del task planning, è stato selezionato un sottoinsieme mirato di 49 immagini. Questi fotogrammi sono stati scelti specificamente per la presenza di grappoli densi con marcate occlusioni reciproche, sovrapposizioni parziali e ombreggiature fogliari, costituendo il banco di prova ideale per verificare e confrontare l'efficacia delle diverse strategie di prelievo.

4.1.2 Configurazione del Modulo Percettivo (YOLOv11-seg)

La segmentazione delle istanze costituisce il primo stadio della pipeline decisionale. In questo lavoro si è scelto di utilizzare il modello **YOLO11-x** (Extra-Large) con risoluzione di inferenza a $\text{imgsz} = 800$ pixel, configurazione già ottimizzata e convalidata nelle precedenti attività di laboratorio [6]¹ con un mAP@50-95 del 40.8% e una precisione del 79.0%.

Il presente lavoro si concentra infatti sulla fase successiva al rilevamento: partendo dalle maschere binarie fornite dalla rete, l'obiettivo è determinare una sequenza di raccolta ordinata, efficiente e priva di collisioni. Per questo motivo la soglia di confidenza è stata mantenuta a $\text{conf} = 0.30$, così da massimizzare la sensibilità del modello anche sui pomodori parzialmente nascosti e lasciare alle successive fasi geometriche il compito di filtrare le maschere non affidabili.

4.1.3 Ambiente di Esecuzione e Parametri Operativi

Tutti i moduli dell'algoritmo sono stati implementati in linguaggio Python 3.12, sfruttando le librerie PyTorch per l'inferenza del modello di deep learning e OpenCV per le primitive algebriche e geometriche (Convex Hull, fitting ellittico, trasformazioni nello spazio colore HSV e operazioni morfologiche binarie).

A fini di tracciabilità e riproducibilità sperimentale, in Tabella 2 vengono riepilogati tutti i parametri operativi fissati per i test della pipeline decisionale, coerentemente con le formulazioni matematiche dedotte nel Capitolo 3.

4.2 Analisi Comparativa delle Strategie di Picking

La validazione sperimentale richiede un confronto quantitativo diretto con le metodologie convenzionali di selezione dei target. L'obiettivo è verificare se la modellazione mediante

¹A. Collega, «Analisi comparativa di modelli YOLO per il rilevamento e la segmentazione del pomodoro nell'ambito dell'agricoltura di precisione per la raccolta robotizzata,» Tesi di Laurea Triennale, Università degli Studi di Milano, 2025

Tabella 2: Riepilogo dei parametri e delle soglie operative della pipeline decisionale.

Parametro	Simbolo	Valore	Ruolo Operativo
Area minima ammissibile	$A_{\min}$	1500 px	Esclusione preliminare di falsi positivi e sfondo
Soglia di deduplicazione	τ_{dedup}	0.70	Mask-IoU per l'eliminazione di predizioni duplicate
Dimensione del pool	K	8	Numero massimo di candidati ammessi alla Fase 3
Soglia di maturità	τ_{mat}	0.50	Indice HSV M_i : discrimina maturi da ostacoli acerbi
Soglia di occlusione	τ_{occ}	0.15	Rapporto di overlap tra ellissi ρ_{ij} per contatto
Penalità di occlusione	γ_{occ}	0.70	Fattore applicato a frutti frontalmente occlusi
Bonus di sblocco	β_{unlock}	1.20	Moltiplicatore assegnato a frutti liberati da un prelievo
Lunghezza sequenza	$N_{\max}$	3	Numero di target pianificati per ciclo di picking

ellissi orientate e la ripianificazione dinamica offrano un incremento misurabile nell'accuratezza della sequenza di raccolta rispetto all'impiego dei tradizionali riquadri rigidi (*bounding box*).

4.2.1 Metodologia di Benchmark e Criteri di Valutazione

Per quantificare l'impatto della modellazione proposta, è stato condotto un confronto sperimentale a tre vie su immagini reali acquisite in serra:

1. **Ground Truth Umano:** sequenza di raccolta ideale (fino a tre frutti: H_1, H_2, H_3) annotata manualmente da operatori su un sottoinsieme di 21 scene a elevata densità di grappolo, selezionata valutando l'accessibilità visiva e l'assenza di ostacoli frontali.
2. **Baseline Bounding Box:** implementazione di riferimento [6]² che modella i pomodori tramite riquadri rigidi allineati agli assi (AABB) o cerchi isotropi, determinando le occlusioni e la sequenza in modo statico.

²A. Collega, «Analisi comparativa di modelli YOLO per il rilevamento e la segmentazione del pomodoro nell'ambito dell'agricoltura di precisione per la raccolta robotizzata,» Tesi di Laurea Triennale, Università degli Studi di Milano, 2025

3. **Planner Ellittico Proposto:** la pipeline descritta nel Capitolo 3, basata su fitting di ellissi orientate (a_i, b_i, θ_i) , calcolo dell'Area Ownership per l'ordinamento in profondità e ripianificazione dinamica con bonus di sblocco β_{unlock} .

La valutazione si concentra su due criteri principali: la concordanza sulla scelta del primo frutto da raccogliere (Rank 1), che rappresenta la decisione più critica per prevenire collisioni nell'approccio iniziale del robot, e l'aderenza della sequenza completa ($N_{\text{max}} = 3$) rispetto alla strategia umana.

4.2.2 Risultati Quantitativi Globali

L'analisi condotta sull'intero set di test (43 scene valide) ha evidenziato la seguente distribuzione dei comportamenti decisionali:

- In 27 scene su 43 (62.8%), i due algoritmi producono la medesima sequenza di prelievo. Questo risultato attesta che in grappoli sparsi o con sovrapposizioni minime la modellazione ellittica preserva la coerenza con la baseline, senza introdurre distorsioni.
- In 12 scene (27.9%), l'algoritmo ellittico diverge dalla baseline, modificando il target selezionato come Rank 1 oppure invertendo l'ordine di prelievo dei frutti successivi.
- In 4 scene (9.3%), entrambi i metodi segnalano l'assenza di frutti maturi accessibili, comportandosi correttamente come meccanismo di sicurezza (*safe-fail*) in presenza di soli pomodori verdi o totalmente occlusi.

Per valutare la bontà delle decisioni prese dall'algoritmo, si è confrontata la sequenza calcolata con quella annotata manualmente dagli operatori sulle 21 scene ad alta densità. La Tabella 3 riassume la percentuale di concordanza con il riferimento umano per ciascuna delle tre posizioni della sequenza di raccolta ($N_{\text{max}} = 3$).

Tabella 3: Tasso di concordanza con il Ground Truth umano lungo la sequenza di raccolta.

Posizione Target	Scene Valutate	Baseline BBox	Planner Ellittico	Variazione (Δ)
Rank 1	21	17 / 21 (81.0%)	17 / 21 (81.0%)	+0.0%
Rank 2	13	5 / 13 (38.5%)	6 / 13 (46.2%)	+7.7%
Rank 3	10	2 / 10 (20.0%)	4 / 10 (40.0%)	+20.0%

Sul primo frutto da raccogliere (Rank 1), entrambi i metodi ottengono lo stesso risultato complessivo, pari all'81.0% (17 scelte concordi su 21). Andando però a esaminare le singole immagini, si notano delle differenze:

- In 19 scene su 21 (90.5%), la baseline e il planner ellittico scelgono lo stesso identico frutto. In 16 di questi casi la decisione coincide con quella umana, mentre nelle restanti 3 scene entrambi i metodi scelgono un pomodoro diverso rispetto all'operatore. Come illustrato nel caso di Figura 3, in queste scene i frutti appartengono allo stesso gruppo: l'algoritmo assegna il Rank 1 al pomodoro in alto ($G = 0.533$) poiché risulta più isolato e centrale nel fotogramma, mentre l'operatore umano ha preferito iniziare la raccolta dal frutto grande in basso (H_1). Questa divergenza riflette la naturale soggettività dell'annotatore umano rispetto al calcolo deterministico del punteggio geometrico.



Figura 3: Esempio di divergenza tra annotazione umana e punteggio geometrico: (a) Ground Truth umano (H_1, H_2, H_3), che avvia la raccolta dal frutto grande inferiore; (b) Baseline a bounding box (C_1, C_2, C_3) e (c) Planner ellittico (E_1, E_2, E_3), che assegnano entrambi il Rank 1 al pomodoro superiore isolato in virtù del maggiore punteggio geometrico ($G = 0.533$ contro 0.490).

- Nelle altre 2 scene i due metodi prendono strade diverse. In particolare, nel caso mostrato in Figura 4, la bounding box seleziona per errore un frutto centrale coperto (C_1), mentre l'ellisse individua correttamente il frutto libero sulla destra (E_1), allineandosi con l'operatore umano (H_1). Nella seconda scena, al contrario, è la baseline a coincidere con l'umano, mentre il nostro metodo sceglie un frutto adiacente con un'area visibile leggermente maggiore.

Il vero vantaggio delle ellissi si osserva sulle scelte successive (Rank 2 e Rank 3). Man mano che la raccolta procede, la rimozione virtuale del primo pomodoro libera spazio e attiva il bonus di sblocco β_{unlock} per i frutti retrostanti. Con i riquadri rigidi (BBox), gli angoli delle scatole continuano a sovrapporsi anche quando i frutti non si toccano, introducendo false occlusioni; di conseguenza, la concordanza con l'umano cala rapidamente al 38.5% sul Rank 2 e al 20.0% sul Rank 3. Con le ellissi, invece, la forma curva del pomodoro

viene approssimata meglio: la concordanza resta al 46.2% sul secondo frutto e raggiunge il 40.0% sul terzo, raddoppiando il valore della baseline. Questo conferma che l'uso delle ellissi e l'aggiornamento dinamico delle occlusioni servono soprattutto a pianificare bene l'intera sequenza di prelievo, evitando errori a catena dopo la prima presa.

4.2.3 Origine Geometrica delle Divergenze

Come illustrato nel confronto qualitativo di Figura 4, le divergenze emerse tra i due approcci derivano da tre fattori intrinseci alla rappresentazione geometrica:



Figura 4: Confronto qualitativo delle strategie di picking su un grappolo denso: (a) Ground Truth umano (H_1, H_2, H_3), con priorità sul frutto frontale destro; (b) Baseline a bounding box (C_1, C_2, C_3), che tenta erroneamente il prelievo del frutto centrale occluso; (c) Planner ellittico proposto (E_1, E_2, E_3), che modella correttamente l'ingombro e assegna il Rank 1 al pomodoro libero, in piena concordanza con l'operatore.

1. **Eliminazione delle false occlusioni d'angolo:** Un riquadro rettangolare allineato agli assi (AABB) racchiude il pomodoro includendo anche i quattro angoli vuoti, che occupano circa il 21.5% dell'intera scatola (pari a un'area vuota di oltre il 27% rispetto all'ingombro effettivo del frutto, valore che cresce ulteriormente se il pomodoro è allungato e inclinato). Quando due pomodori si trovano vicini in diagonale, gli angoli delle rispettive scatole si sovrappongono pur senza alcun contatto reale tra i frutti. Questo porta la baseline a rilevare una falsa occlusione e ad applicare la penalità $\gamma_{occ} = 0.70$ a un frutto che in realtà è libero.
2. **Rappresentazione dell'eccentricità e dell'orientamento:** I pomodori presentano frequentemente forme ovoidali. L'ellisse orientata cattura fedelmente l'angolo θ_i e i semiassi del frutto, stimando con precisione l'effettiva area di contatto ρ_{ij} tra corpi adiacenti.

3. **Pianificazione dinamica Pick & Update:** La baseline valuta la raggiungibilità in un singolo passaggio statico. Al contrario, la pipeline proposta simula la rimozione del frutto selezionato e aggiorna le occlusioni residue: l'assegnazione del bonus di sblocco $\beta_{\text{unlock}} = 1.20$ promuove i frutti retrostanti liberati dall'azione precedente, rispecchiando l'ordine di rimozione progressivo adottato naturalmente dall'operatore umano.

4.3 Analisi dei Casi Studio e Discussione

L'analisi dei casi studio consente di osservare il comportamento dell'algoritmo su situazioni reali complesse, verificando da vicino come viene gestito lo sblocco dei frutti occlusi, quali fattori determinano la sequenza di raccolta e quali sono i principali limiti pratici del sistema.

4.3.1 Dinamica di Sblocco delle Occlusioni

Il primo caso studio analizza il comportamento della pipeline decisionale sul fotogramma ad alta densità illustrato in Figura 5. La scena presenta un grappolo composto da tre pomodori maturi (T_1, T_2, T_3) e due frutti acerbi sottostanti:

- T_1 , posizionato inferiormente a coordinate (245, 262), con punteggio geometrico iniziale $G_1 = 0.482$;
- T_2 , situato a coordinate (257, 207) immediatamente alle spalle di T_1 , con punteggio geometrico di base $G_2 = 0.466$;
- T_3 , collocato lateralmente a coordinate (314, 179), privo di ostacoli frontali, con punteggio geometrico $G_3 = 0.475$.



Figura 5: Dinamica di sblocco su un grappolo denso con occlusioni multiple. (a) Ground Truth umano (H_1, H_2, H_3); (b) Baseline a bounding box (C_1, C_2, C_3); (c) Planner ellittico (E_1, E_2, E_3), in cui la rimozione di E_1 sblocca E_2 assegnandogli il bonus $\beta_{\text{unlock}} = 1.20$ e consentendogli di scavalcare il frutto laterale E_3 .

Alla prima iterazione ($t = 1$), l'algoritmo valuta T_1 come frutto più accessibile e lo assegna al Rank 1 ($S_1 = 0.482$). Poiché T_1 si trova frontalmente rispetto a T_2 , la simulazione del suo prelievo azzerla la sovrapposizione reciproca ($\rho_{12} = 0$), liberando il target retrostante. Al passo successivo ($t = 2$), al pomodoro T_2 viene quindi applicato il bonus di sblocco $\beta_{\text{unlock}} = 1.20$, aggiornandone il punteggio a:

$$S_2 = G_2 \times \beta_{\text{unlock}} = 0.466 \times 1.20 = 0.559 \quad (24)$$

Senza questo incentivo, T_2 (0.466) sarebbe rimasto subordinato a T_3 (0.475), spingendo il pianificatore a selezionare il frutto laterale. Grazie al moltiplicatore dinamico, T_2 scavalca T_3 ($0.559 > 0.475$) e viene raccolto come Rank 2, lasciando T_3 al Rank 3.

Dal punto di vista pratico, questo comportamento è vantaggioso per due motivi:

- **Sicurezza meccanica:** poiché T_1 si trova davanti a T_2 , tentare di raccogliere direttamente T_2 comporterebbe il rischio di urtare e danneggiare il frutto antistante con le dita della pinza. Raccogliere prima T_1 libera il corridoio di accesso frontale per il braccio.
- **Continuità sul grappolo locale:** all'inizio il pomodoro T_2 aveva un punteggio più basso ($G_2 = 0.466$) rispetto al frutto laterale T_3 ($G_3 = 0.475$) solo perché l'occlusione di T_1 ne nascondeva una parte, riducendone l'area visibile alla telecamera. Senza il bonus di sblocco, dopo aver tolto T_1 il robot sarebbe "saltato" sul frutto laterale T_3 , lasciando indietro T_2 . Il moltiplicatore $\beta_{\text{unlock}} = 1.20$ compensa questo svantaggio visivo iniziale, consentendo al manipolatore di completare la raccolta dei pomodori contigui sullo stesso grappolo prima di spostarsi su altri tralci.

4.3.2 Inversione delle Priorità e Frutti Allungati

Il secondo caso studio, illustrato in Figura 6, mostra come l'uso delle ellissi risolva i limiti dei modelli rettangolari quando i pomodori hanno una forma allungata.



Figura 6: Inversione delle priorità di picking su un grappolo verticale. (a) Scelta umana di riferimento (H_1, H_2, H_3). (b) Baseline BBox (C_1, C_2, C_3), che sceglie per errore il frutto centrale (C_2) prima di quello in basso (C_3). (c) Planner ellittico (E_1, E_2, E_3), che si adatta alla forma allungata del pomodoro inferiore assegnandogli il Rank 2 (E_2), rispecchiando esattamente la scelta dell'operatore umano.

La scena mostra un grappolo verticale con tre pomodori in primo piano lungo il tralcio. Entrambi i metodi concordano nell'assegnare il Rank 1 al pomodoro in alto a coordinate (147, 163), che è maturo e del tutto libero da ostacoli. La differenza fondamentale riguarda la scelta del secondo frutto da raccogliere, tra quello centrale a (145, 254) e quello in basso a (126, 331):

- La baseline a Bounding Box seleziona il pomodoro centrale (145, 254) come Rank 2 (C_2) e lascia per ultimo quello in basso (126, 331) al Rank 3 (C_3);
- Il nostro planner a ellissi inverte l'ordine: raccoglie prima il pomodoro in basso (126, 331) come Rank 2 (E_2) e poi quello centrale (145, 254) come Rank 3 (E_3), esattamente nello stesso ordine scelto dall'operatore umano ($H_1 \rightarrow H_2 \rightarrow H_3$).

Questo cambiamento è dovuto alla forma allungata del pomodoro inferiore, che ha un'altezza quasi doppia rispetto alla larghezza (semiassi di 30.7 px e 57.1 px, con un rapporto di 1.86 : 1). La baseline usa un riquadro rettangolare che allarga troppo l'area occupata ai lati, facendo credere al sistema che il pomodoro centrale sia sopra a quello inferiore. L'ellisse inclinata ($\theta \approx 3.2^\circ$), invece, segue con precisione la forma reale del frutto: l'algoritmo capisce quindi che il pomodoro in basso è libero e può essere raccolto subito, senza rischiare collisioni.

Oltre alla corretta stima delle sovrapposizioni, questo caso evidenzia un netto miglioramento nel calcolo del punteggio geometrico G . Nella baseline di riferimento, il perimetro del frutto viene calcolato direttamente sul contorno grezzo della maschera di segmentazione, che presenta bordi frastagliati e a gradino; questo fa aumentare artificialmente il perimetro misurato ($P = 313.2$ px) e abbassa la circolarità a $C = 0.631$. Nel nostro approccio, l'uso dell'involucro convesso (*Convex Hull*) prima del fitting dell'ellisse regolarizza i contorni, riducendo il perimetro a $P = 283.1$ px e portando la circolarità a $C = 0.772$ (+0.141). Questo incremento migliora direttamente lo score geometrico G , fornendo una stima della raggiungibilità più realistica e stabile rispetto alla maschera grezza.

4.3.3 Limiti Sistemici e Condizioni Critiche

L'analisi sperimentale ha evidenziato due limiti pratici della pipeline, che indicano le direzioni per i futuri sviluppi:

1. **Zone di forte ombra e filtro di maturità:** La distinzione tra pomodori maturi e acerbi si basa su soglie minime di colore e luminosità nello spazio HSV ($S > 50$ e $V > 50$). Quando un frutto si trova sotto una fitta ombra fogliare, molti dei suoi pixel risultano troppo bui per superare la soglia. La forte riduzione dei pixel analizzabili rende il calcolo della maturità più fragile ed esposto a disturbi dello sfondo. In futuro, questo limite potrà essere superato adottando soglie che si adattano automaticamente alla luce della scena, oppure addestrando una piccola rete neurale dedicata unicamente a riconoscere la maturazione.
2. **Frutti completamente nascosti e visione da singolo punto di vista:** L'algoritmo elabora una sola inquadratura fotografica fissa. Se un pomodoro maturo è interamente coperto da foglie o posizionato dietro al fusto della pianta, la telecamera non può rilevarlo in alcun modo. Questo evidenzia il limite della visione statica e la necessità di passare a strategie di *Active Vision*: muovendo la telecamera con il braccio robotico attorno al grappolo, il sistema potrà esplorare la pianta da diverse angolazioni e individuare anche i frutti inizialmente non visibili.

Capitolo 5

Conclusioni e Sviluppi Futuri

Il lavoro svolto in questa tesi ha affrontato il problema della raccolta automatizzata di pomodori in serra, concentrandosi sulla pianificazione della sequenza di prelievo all'interno di grappoli densi e complessi.

Nel quadro di un approccio di visione attiva (*Active Vision*), l'analisi accurata della singola inquadratura rappresenta il primo passo indispensabile: prima ancora di muovere la telecamera attorno alla pianta per cercare frutti nascosti, il sistema deve saper gestire le occlusioni visibili e pianificare una sequenza sicura per evitare collisioni.

Di seguito vengono riassunti i principali risultati raggiunti con la modellazione ellittica e la ripianificazione dinamica, delineando poi le prospettive per i futuri sviluppi e l'integrazione robotica.

5.1 Sintesi dei Risultati e Contributi della Tesi

La raccolta robotizzata in serra richiede di individuare con precisione l'ordine di presa dei frutti, soprattutto all'interno di grappoli densi dove le occlusioni reciproche rendono rischioso l'avvicinamento del robot. I metodi tradizionali, basati su riquadri rettangolari rigidi (*bounding box*) o stime statiche, mostrano forti limiti quando i pomodori sono a stretto contatto o presentano forme allungate.

Per superare queste criticità, è stata sviluppata e validata una pipeline decisionale basata su tre passaggi principali:

1. **Regolarizzazione geometrica con Convex Hull:** l'applicazione dell'involucro convesso sulle maschere di YOLO11-x ha permesso di ripulire i bordi a gradino, rendendo il calcolo del perimetro e della circolarità stabile e realistico;

2. **Modellazione ellittica orientata:** l'approssimazione dei pomodori mediante ellissi orientate ha eliminato le false occlusioni d'angolo tipiche dei rettangoli rigidi (in cui l'area vuota negli angoli occupa circa il 21.5% della scatola), adattandosi all'inclinazione e alla forma reale del frutto;
3. **Task planning dinamico *Pick & Update*:** la simulazione del prelievo a ogni passo con l'assegnazione del bonus di sblocco ($\beta_{\text{unlock}} = 1.20$) ha consentito di ripianificare la sequenza, premiando i frutti retrostanti appena liberati e trattando i pomodori acerbi come ostacoli statici da non urtare.

La sperimentazione condotta sulle immagini reali di serra ha confermato la validità del metodo proposto.

Analizzando l'intero set di 43 scene, nel 62.8% dei casi (27 scene) la sequenza prodotta coincide con quella della baseline, confermando che nei grappoli semplici il modello non introduce distorsioni. Nelle scene dense (12 casi, 27.9%), l'algoritmo corregge errori di precedenza dovuti a contatti diagonali, mentre in 4 scene (9.3%) rileva correttamente l'assenza di frutti maturi accessibili, arrestando la raccolta in sicurezza (condizione di *safe-fail*).

Sul benchmark di 21 scene ad alta densità con riferimento umano, sia la baseline sia il modello proposto registrano una concordanza dell'81.0% sul primo frutto da raccogliere (Rank 1, 17 casi su 21). Tuttavia, un'analisi puntuale delle scene rivela come i due approcci giungano a tale risultato per vie profondamente diverse. Nelle situazioni in cui la baseline fallisce, l'errore è causato dalla geometria rigida dei riquadri rettangolari, i cui angoli vuoti inducono false occlusioni che spingono il sistema a selezionare frutti parzialmente coperti. Al contrario, le divergenze del planner ellittico non comportano rischi di collisione, ma si verificano quando più pomodori risultano ugualmente accessibili: in tali contesti, l'algoritmo privilegia deterministicamente il frutto con il punteggio geometrico più elevato (ad esempio per una maggiore centralità ottica), a fronte di una scelta soggettiva dell'operatore.

La reale efficacia della modellazione curvilinea e della pianificazione dinamica emerge sui prelievi successivi. Grazie all'aggiornamento iterativo dello stato e all'introduzione del bonus di sblocco ($\beta_{\text{unlock}} = 1.20$), la concordanza con l'operatore umano sale al 46.2% sul secondo frutto (rispetto al 38.5% della baseline) e raggiunge il 40.0% sul terzo, raddoppiando l'accuratezza del modello convenzionale (20.0%).

Infine, dal punto di vista computazionale, la scelta di selezionare a monte un pool ristretto di $K = 8$ candidati limita i confronti tra ellissi a un massimo di 56 verifiche geometriche. Questo rende l'algoritmo leggero e veloce, adatto a essere eseguito in tempo reale a bordo di un sistema robotico.

5.2 Sviluppi Futuri e Integrazione Robotica

I risultati ottenuti in questo lavoro confermano l'efficacia dell'approccio geometrico e dinamico per la pianificazione della raccolta su singola inquadratura. Trattandosi di uno studio incentrato sulla componente algoritmica e decisionale, il naturale proseguimento di questa ricerca riguarda il trasferimento della pipeline a bordo di un manipolatore robotico operativo e la risoluzione dei limiti pratici riscontrati durante la sperimentazione.

Il primo passo verso l'applicazione fisica consiste nel passaggio dalle coordinate del piano immagine allo spazio operativo tridimensionale. Utilizzando una telecamera di profondità RGB-D, la posizione bidimensionale (u, v) del centroide calcolato dalla nostra pipeline può essere combinata con il canale di profondità per ricavare le coordinate cartesiane (X, Y, Z) nel sistema di riferimento ottico della telecamera, mediante la matrice dei parametri intrinseci del sensore [1]¹. In questa fase, per evitare che rumore ottico o riflessi alterino la misura, la profondità Z del pomodoro potrà essere calcolata come mediana dei pixel validi all'interno della maschera di segmentazione. Inoltre, l'angolo di inclinazione θ restituito dal fitting dell'ellisse fornirà l'orientamento necessario per allineare la pinza di presa lungo l'asse principale del frutto, agevolando il distacco meccanico dal peduncolo. Attraverso il middleware ROS 2 e il pacchetto di trasformazioni spaziali tf2, le coordinate verranno quindi convertite rispetto alla base del manipolatore (come il braccio industriale ABB presente nel setup sperimentale) e inviate a MoveIt 2 [15]². Il framework di motion planning potrà così generare traiettorie prive di collisioni nello spazio dei giunti, guidando l'organo di presa verso i frutti secondo l'ordine di priorità calcolato dal nostro planner.

Un secondo fronte di evoluzione riguarda il superamento dei limiti imposti dalla visione da un singolo punto di vista. Come osservato analizzando le immagini di test in *immaginiPerAlgoritmo*, l'algoritmo gestisce con successo le occlusioni parziali tra pomodori adiacenti, ma non può individuare frutti maturi completamente nascosti dietro il fusto o sotto uno strato fitto di vegetazione. La soluzione naturale consiste nell'integrare la pipeline sviluppata all'interno di una strategia di visione attiva (*Active Vision*) [2]³. Montando il sensore visivo direttamente sul polso del manipolatore (*eye-in-hand*), il robot potrà compiere movimenti esplorativi attorno alla pianta per acquisire viste complementari da angolazioni diverse (*Next-Best-View*). In questo scenario, la nostra pipeline agirà come decisore locale: a ogni nuova inquadratura, il modello mapperà le occlusioni visibili e aggiornerà la lista dei frutti da raccogliere, integrando progressivamente la conoscenza del grappolo man mano che i movimenti del braccio svelano i pomodori precedentemente occlusi.

¹A. Gongal et al., «Sensors and Systems for Fruit Detection and Localization: A Review,» *Computers and Electronics in Agriculture*, vol. 116, pp. 8–19, 2015. doi: 10.1016/j.compag.2015.05.021

²S. Chitta et al., «MoveIt! [ROS Topics],» *IEEE Robotics & Automation Magazine*, vol. 19, n. 1, pp. 18–19, 2012. doi: 10.1109/MRA.2011.2181749

³A. Silwal et al., «Design, Integration, and Field Evaluation of a Robotic Apple Harvester,» *Journal of Field Robotics*, vol. 34, n. 6, pp. 1140–1159, 2017. doi: 10.1002/rob.21715

Infine, un'ulteriore linea di sviluppo riguarda la robustezza del filtro di maturità. L'analisi delle condizioni critiche ha evidenziato come l'impiego di soglie rigide nello spazio colore HSV ($S > 50, V > 50$) mostri fragilità in presenza di forti zone d'ombra, dove la scarsa luminosità rischia di far escludere dal conteggio molti pixel rossi. Per superare questa limitazione senza compromettere la semplicità computazionale del sistema, si prospettano due alternative: la transizione allo spazio colore CIELAB ($L^*a^*b^*$), in cui il canale cromatico a^* (che misura la transizione dal verde al rosso) è disaccoppiato dall'intensità luminosa L^* risultando pressoché immune alle ombre; oppure l'addestramento di una rete convoluzionale leggera (come MobileNetV3) operante direttamente sui ritagli dei singoli pomodori individuati da YOLO [14]⁴. Quest'ultima soluzione permetterebbe di stimare il grado di maturazione basandosi anche sulla tessitura superficiale del frutto, riconoscendo con maggiore affidabilità anche le fasi intermedie di viraggio del colore.

⁴B. Xiao et al., «Fruit ripeness identification using YOLOv8 model,» *Multimedia Tools and Applications*, vol. 83, n. 11, pp. 33 737–33 754, 2024. DOI: 10.1007/s11042-023-16570-9

Bibliografia

- [1] A. Gongal, S. Amatya, M. Karkee, Q. Zhang e K. Lewis, «Sensors and Systems for Fruit Detection and Localization: A Review,» *Computers and Electronics in Agriculture*, vol. 116, pp. 8–19, 2015. DOI: 10.1016/j.compag.2015.05.021
- [2] A. Silwal, J. R. Davidson, M. Karkee, C. Mo, Q. Zhang e K. Lewis, «Design, Integration, and Field Evaluation of a Robotic Apple Harvester,» *Journal of Field Robotics*, vol. 34, n. 6, pp. 1140–1159, 2017. DOI: 10.1002/rob.21715
- [3] K. He, G. Gkioxari, P. Dollár e R. Girshick, «Mask R-CNN,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, n. 2, pp. 386–397, 2020. DOI: 10.1109/TPAMI.2018.2844175
- [4] J. Redmon, S. Divvala, R. Girshick e A. Farhadi, «You Only Look Once: Unified, Real-Time Object Detection,» in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91
- [5] G. Liu, J. C. Nouaze, P. L. Touko Mbouembe e J. H. Kim, «YOLO-Tomato: A Robust Algorithm for Tomato Detection Based on YOLOv3,» *Sensors*, vol. 20, n. 7, p. 2145, 2020. DOI: 10.3390/s20072145
- [6] A. Collega, «Analisi comparativa di modelli YOLO per il rilevamento e la segmentazione del pomodoro nell’ambito dell’agricoltura di precisione per la raccolta robotizzata,» Tesi di Laurea Triennale, Università degli Studi di Milano, 2025.
- [7] C. W. Bac, E. J. van Henten, J. Hemming e Y. Edan, «Harvesting Robots for High-Value Crops: State-of-the-Art Review and Challenges Ahead,» *Journal of Field Robotics*, vol. 31, n. 6, pp. 888–911, 2014. DOI: 10.1002/rob.21525
- [8] X. Chen e S. X. Yang, «A practical solution for ripe tomato recognition and localisation,» *Journal of Real-Time Image Processing*, vol. 8, n. 1, pp. 35–51, 2013. DOI: 10.1007/s11554-011-0222-9
- [9] Y. Changhui, W. Yi, L. Yanping e H. Lin, «Reconstruction Method of Overlapped Citrus Fruits in Natural Scenes Based on Convex Hull,» in *Proceedings of the International Conference on Computer Systems, Electronics and Control (ICCSEC)*, IEEE, 2017, pp. 1095–1098. DOI: 10.1109/ICCSEC.2017.8447005

- [10] S. Wang e T. Luo, «A Multi-Fruit Recognition Method for a Fruit-Harvesting Robot Using MSA-Net and Hough Transform Elliptical Detection Compensation,» *Horticulturae*, vol. 10, n. 10, p. 1024, 2024. DOI: 10.3390/horticulturae10101024
- [11] A. Fitzgibbon, M. Pilu e R. B. Fisher, «Direct least squares fitting of ellipses,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 21, n. 5, pp. 476–480, 1999. DOI: 10.1109/34.765658
- [12] J. D. Žunić e P. L. Rosin, «A New Convexity Measure for Polygons,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, n. 7, pp. 923–934, 2004. DOI: 10.1109/TPAMI.2004.19
- [13] A. Ahmad, J. Lloret, L. Parra, S. Sendra e F. Di Gioia, «Comparative Analysis of R-CNN and YOLOv8 Segmentation Features for Tomato Ripening Stage Classification and Quality Estimation,» *Horticulturae*, vol. 12, n. 2, p. 127, 2026. DOI: 10.3390/horticulturae12020127
- [14] B. Xiao, M. Nguyen e W. Q. Yan, «Fruit ripeness identification using YOLOv8 model,» *Multimedia Tools and Applications*, vol. 83, n. 11, pp. 33 737–33 754, 2024. DOI: 10.1007/s11042-023-16570-9
- [15] S. Chitta, I. Sucan e S. Cousins, «Moveit! [ROS Topics],» *IEEE Robotics & Automation Magazine*, vol. 19, n. 1, pp. 18–19, 2012. DOI: 10.1109/MRA.2011.2181749
- [16] J. Sun, X. He, X. Ge, X. Wu, J. Shen e Y. Song, «TomatoDet: Anchor-free Detector for Tomato Detection,» *Frontiers in Plant Science*, vol. 13, p. 942 875, 2022. DOI: 10.3389/fpls.2022.942875